



G57

SISTEMA DE EVALUACIÓN DE RIESGO CREDITICIO






Agenda

- Visión general
- ¿Qué Buscamos Predecir?
- Fortaleciendo la Decisión, No Reemplazándola
- Decisiones
- ¿De Dónde Proviene Nuestros Datos?
- Recolección de Datos
- Representación Digital del Solicitante
- Construcción de Modelos
- Realización de Predicciones
- Simulación del Impacto
- Midiendo el Éxito de Forma Continua
- Conclusiones


ROLES



DATA ENGINEER

Maximiliano Zapater Cornejo


A01840258@tec.mx



CIENTÍFICO DE DATOS

José Luis Parada Guitiérrez


A00939669@tec.mx



SOFTWARE ENGINEER

Julián Jesús Moreno Ovando.


A01795915@tec.mx



ML ENGINEER

Oscar Luis Guadarrama Jiménez.

A01796245@tec.mx



DEVOPS

Ronald Sandí Quesada

A01794620@tec.mx



G57

Data Engineer: Roles y funciones

El **Data Engineer** es el responsable de diseñar y mantener la **infraestructura** que permite que los datos fluyan, se transformen y estén **disponibles** para generar valor.



Este rol combina **arquitectura de datos, automatización y calidad**, debemos asegurar que la información sea **accesible, confiable y escalable**.

Responsable de **conectar los sistemas** de origen con el resto del equipo.

Etapa 1: Prototipado colaborativo



La **limpieza y exploración** de los datos se realiza en **notebooks**, priorizando el entendimiento del dataset y las variables relevantes.

El objetivo es **disponibilizar la data** y asegurar su **trazabilidad mediante DVC y Google Drive**, controlando versiones y experimentos.

En esta fase se trabaja con una **base histórica inicial en formato CSV**, que servirá como punto de partida para **entrenar el modelo**.

Más adelante, este flujo se **refactorizará y automatizará**, convirtiéndose en el **pipeline** base del proyecto.




Etapa 2: Preproducción y estrategia de zonas de datos




Estrategia de datos:


El enfoque se traslada hacia la estructura y calidad del flujo de datos.



“donde se almacenan los
datos originales sin alterar”




“donde se limpian y
transforman ”



“donde se publican en
formatos optimizados para
análisis o modelamiento”



Etapa 3: Producción y mejora continua



Foco en la **orquestración**, **observabilidad** y **gobernanza** del dato, utilizando herramientas como Airflow, Spark o Dataflow para procesar grandes volúmenes, y BigQuery para el almacenamiento analítico.

Los resultados son **consumidos por diferentes equipos** como Business Intelligence o Machine Learning, ej: mediante Vertex AI.

Existe **retroalimentación continua**, donde las **inferencias** en producción alimentan nuevas bases de entrenamiento, permitiendo **monitoreo y una mejora constante del modelo**.

La **arquitectura** debe ser:

ESCALABLE

AUTOMATICA

ROBUSTA



G57

Funciones del ML Engineer

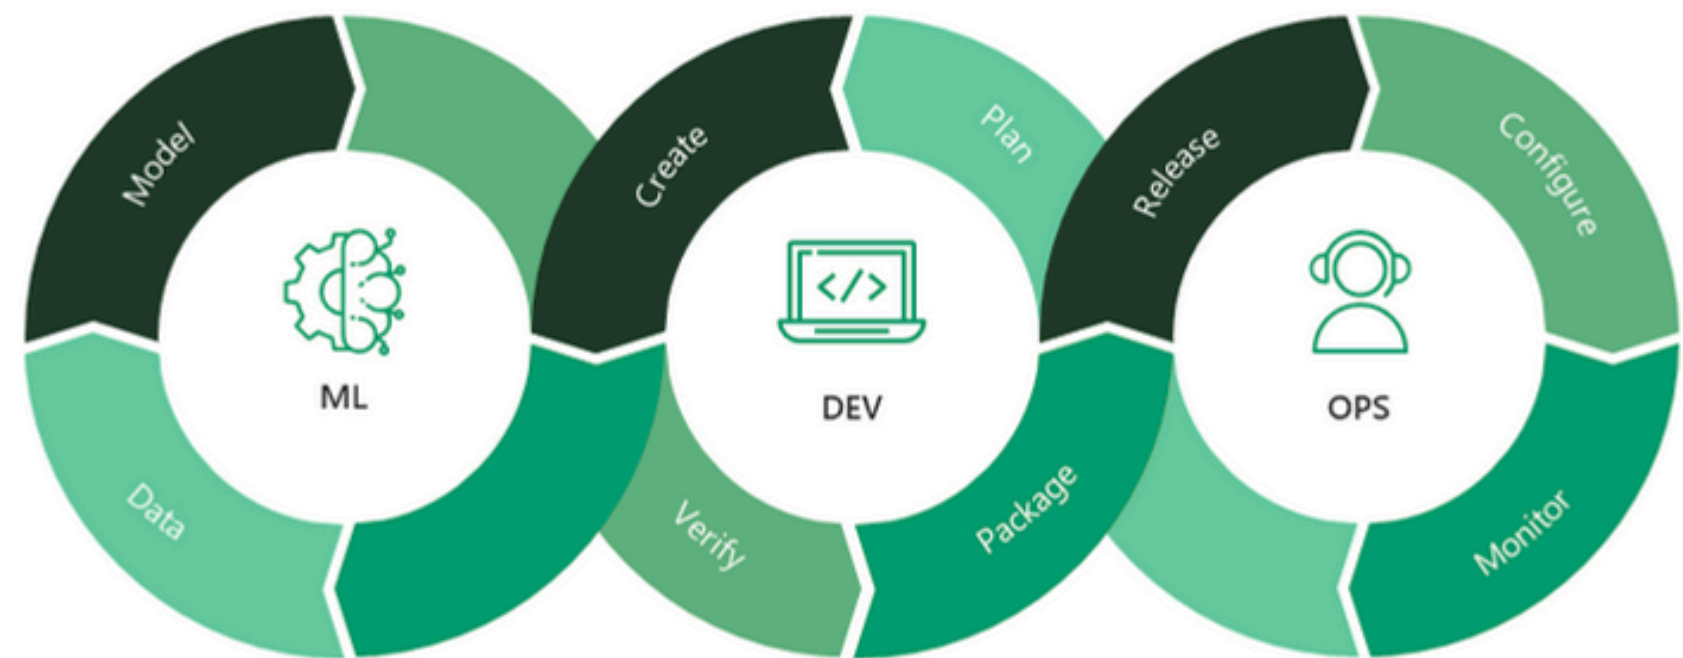
- Diseñar el entorno de entrenamiento → asegurar reproducibilidad y escalabilidad.
- Implementar pipelines MLOps → automatizar limpieza, modelado y evaluación
- Monitorear el rendimiento y el data drift → detectar desviaciones y activar retraining.
- Garantizar despliegue y mantenimiento → integrar el modelo en producción de forma segura.



G57

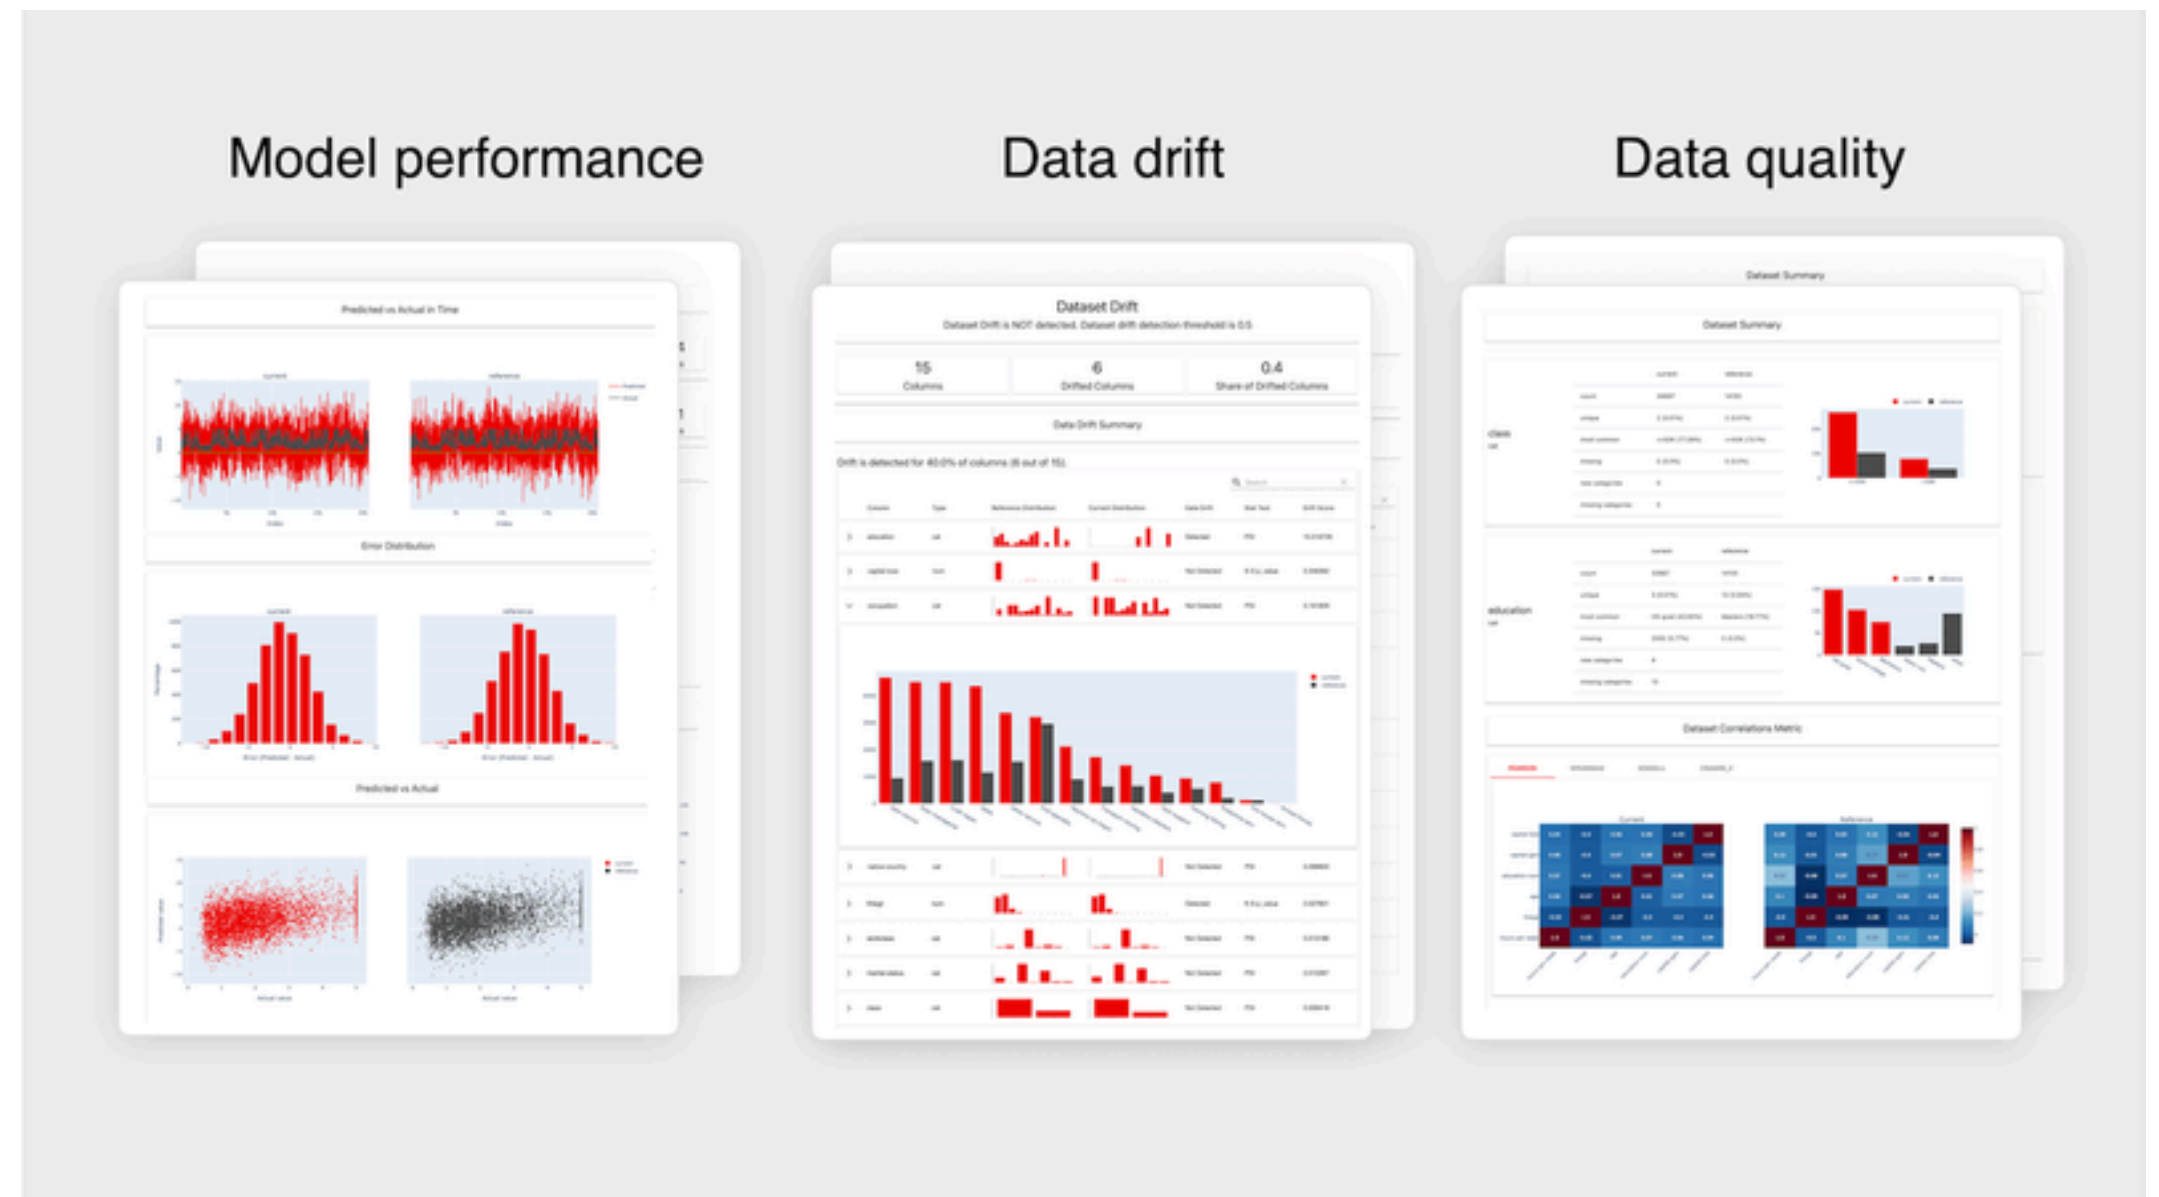
Entorno de Entrenamiento

- Python 3.11 + Conda
- Git / GitHub / DVC
- MLflow + GitHub Actions



Monitoreo y Data Drift

- Evidently AI → Population Stability Index
- Activación automática de retraining
- Monitoreo mensual o por lote





G57

Funciones del Software Engineer



El Ingeniero de Software se centrará en robustecer la aplicación que consume el modelo, asegurando que cumpla con los estándares de producción.

1. Refactorización y Profesionalización de la API

- Reconstruir el servicio aplicando principios de Programación Orientada a Objetos (POO) y diseño modular.
- Alinear el código con la estructura estandarizada del proyecto (Cookiecutter) para mejorar la mantenibilidad.

2. Integración Dinámica con el Registro de Modelos (MLflow)

- Conectar la API al MLflow Model Registry para consumir el modelo.
- Implementar la carga dinámica de la versión del modelo marcada como "Producción", desacoplando las actualizaciones del modelo del ciclo de despliegue de la aplicación.

3. Implementación de Estándares de Producción

- Seguridad: Implementar autenticación y encriptación de datos en tránsito.
- Escalabilidad: Diseñar la arquitectura para soportar peticiones concurrentes de múltiples analistas.
- Rendimiento: Garantizar el cumplimiento del requerimiento clave: Tiempo de respuesta inferior a 2 segundos por predicción.

[Volver a la Agenda](#)



G57

ML CANVAS

<p>PREDICTION TASK Tarea: Clasificación binaria de aptitud crediticia. Entidad: Cliente-Crediticio (solicitante de crédito). Variable objetivo: credit_risk - Cumplimiento o incumplimiento de pago. Resultados: Apto / No apto para crédito. Observación: Posterior al análisis de características sociales, económicas y personales.</p>	<p>DECISIONS Resultado positivo: Iniciar procesos comerciales (oferta de productos financieros). Resultado negativo: Detener proceso inmediatamente para evitar pérdidas. Rol del sistema: Herramienta de apoyo que fortalece (no reemplaza) el criterio del analista. Salida: Predicción binaria con nivel de confianza opcional.</p>	<p>VALUE PROPOSITION</p> <p>Usuario final: Analistas crediticios de la Entidad-Bancaria-Prestamista.</p> <p>Objetivo principal: Sistema de inteligencia aumentada para mejorar el proceso de evaluación de riesgo crediticio.</p> <p>Beneficios clave:</p> <ul style="list-style-type: none">Mejora en la asignación de créditos mediante análisis objetivo basado en datos.Aumento de la eficiencia operativa del proceso de evaluaciónReducción del riesgo en la cartera crediticia de la entidadOptimización del tiempo del analista evitando asignación de recursos a casos de alto riesgo <p>Flujo de trabajo: El sistema genera predicciones que se comunican a la entidad para facilitar la toma de decisiones sobre aprobación crediticia y oferta de productos financieros.</p>	<p>DATA COLLECTION Prototipo: Ingesta directa desde CSV (South German Credit Dataset). Producción: Automatización vía SQL queries sobre GCP, con herramientas como BigQuery y Cloud SQL. Frecuencias: Streaming, batch diario, semanal o mensual según SLA.</p> <p>Arquitectura de 3 capas:</p> <ul style="list-style-type: none">Raw: Almacenamiento inmutable en Cloud Storage con versionadoStaging: Limpieza, validación, transformaciones y codificacionesCurated: Datos listos en Parquet para análisis/reentrenamiento en AutoML.	<p>DATA SOURCES Prototipo: South German Credit Dataset (UCI). Producción - Internas:</p> <p>Tablas de clientes con datos personales/sociales/económicos Transacciones crediticias Resultados de pago (variable kredit)</p> <p>Producción - Externas: Enriquecimiento vía APIs para complementar perfiles.</p>
<p>IMPACT SIMULATION Matriz Costo/Beneficio: VP (apto/paga): +1.0 FP (apto/no paga): -3.0 VN (no apto/hubiera incumplido): +0.5 FN (no apto/hubiera pagado): -1.0</p> <p>Requisitos de implementación: Precisión ≥ 80% Recall ≥ 70% (clase riesgo alto) EMV positivo Tiempo respuesta < 2 seg Equal Opportunity Difference ≤ ±0.1 (equidad)</p>	<p>MAKING PREDICTIONS Modalidad: Predicciones individuales en tiempo real a demanda. Tiempo de respuesta: < 2 segundos.</p> <p>Infraestructura: Cliente: PC del analista Servidor: Cloud/on-premise con modelo ML Flujo: Ingreso datos → transmisión → procesamiento → resultado en pantalla</p>	<p>MONITORING KPIs para Analistas (Usuarios Finales):</p> <ul style="list-style-type: none">Tasa de Adopción: % de analistas usando la herramienta diariamenteTiempo por Solicitud: Reducción vs. proceso anteriorSatisfacción del Usuario: Encuestas sobre utilidad y experiencia <p>KPIs para el Banco (Negocio):</p> <ul style="list-style-type: none">Tasa de Incumplimiento: % préstamos malos con herramienta vs. sin herramientaPrecisión del Modelo: % de créditos "Recomendados" que pagaron correctamenteVolumen de Solicitudes Procesadas: Capacidad de evaluación en mismo periodoRetorno de Inversión (ROI): Costo desarrollo/mantenimiento vs. ahorros por evitar malos préstamos <p>Frecuencia:</p> <ul style="list-style-type: none">Semanal/Mensual: Adopción, tiempo por solicitud, correcciones manuales (detección rápida de problemas operativos)Trimestral: Precisión del modelo, volumen de solicitudes (validación técnica y operativa)Semestral/Anual: Tasa de incumplimiento, ROI (prueba final de éxito del proyecto)	<p>BUILDING MODELS Modelos evaluados (7): Regresión Logística, k-NN, Árbol de Decisión, Random Forest, XGBoost, MLP, SVC.</p> <p>Criterios: Rendimiento, interpretabilidad, costo computacional.</p> <p>Desarrollo:</p> <ul style="list-style-type: none">Prototipado en Google ColabEscalamiento a producción en Google Cloud Platform con GPU <p>Timeline: 2-4 semanas.</p>	<p>FEATURES Total: 20 características en 4 familias. Binarios (4): credit_risk, foreign_worker, people_liable, telephone Categorías (7): credit_history, housing, other_debtors, installment_plans, personal_status_sex, purpose, savings, status Ordinales (6): employment_duration, installment_rate, job, number_credits, present_residence, property Cuantitativas (3): age, amount, duration Preprocesamiento:</p> <p>Limpieza: imputación de nulos, tratamiento de outliers Transformaciones: normalización, codificación one-hot/ordinal Balanceo: SMOTE/undersampling si necesario División: train/validation/test</p>



G57



¿Qué Buscamos Predecir?

El núcleo de este proyecto es una tarea de clasificación binaria para determinar la viabilidad de un solicitante de crédito.

ENTIDAD

El Cliente-Crediticio que solicita un préstamo.

PREDICCIÓN

Si el cliente es apto o no apto para recibir el crédito.

OBJETIVO

Predecir el riesgo de incumplimiento antes de otorgar el financiamiento, basándonos en el perfil del solicitante al momento de la solicitud.

[Volver a la Agenda](#)




Fortaleciendo la Decisión, No Reemplazándola

OBJETIVIDAD

Proporciona un análisis objetivo y basado en datos que complementa su evaluación.

EFICIENCIA

Aumenta la eficiencia operativa del proceso de evaluación.




REDUCE EL RIESGO

Reduce el riesgo financiero en la cartera de préstamos.

PRECISIÓN

Mejora en precisión la asignación de créditos.

[Volver a la Agenda](#)



Decisiones

Las predicciones del modelo se convierten en recomendaciones directas para el analista de crédito

- **Predicción "Apto":** La recomendación es continuar con el proceso y ofertar productos financieros al cliente.
- **Predicción "No Apto":** La recomendación es detener el proceso inmediatamente para evitar riesgos y pérdidas.

Este sistema funciona como una herramienta de apoyo que no reemplaza al analista. Su eficacia se basa en estos parámetros clave:

- **Salida Binaria:** El modelo ofrece un resultado claro de "apto" o "no apto".
- **Operación a Demanda:** Las predicciones se generan en tiempo real, una por una, solo cuando el analista lo necesita.
- **Respuesta Rápida:** El sistema responde en menos de 2 segundos para no interrumpir el flujo de trabajo.

[Volver a la Agenda](#)

¿De Dónde Proviene Nuestros Datos?

El modelo se construye sobre una base de datos sólida y se integra con los sistemas existentes del banco para escalar a producción.

Fase de Prototipo

Se utiliza el South German Credit Dataset (Repositorio UCI), un conjunto de datos público y validado.

Fase de Producción

Se conecta a las bases de datos internas del banco (clientes, transacciones, historial crediticio).

Diseñado para integrar fuentes externas vía API para enriquecer el perfil del cliente.

Estrategia de Datos

RAW

Ingesta de datos originales sin modificar. Mantiene una copia inmutable para auditoría.

STAGING

Limpieza, validación y transformación de los datos. Aquí se actualiza el resultado real del crédito una vez finalizado.

CURATED


La fuente de datos consolidada y validada, lista para el reentrenamiento continuo del modelo.

[Volver a la Agenda](#)

Representación Digital del Solicitante (features)


Familia del Parámetro	Canónico original	Parámetro traducido	Detalle
Binario	kredit	credit_risk	Cumplimiento o no cumplimiento del crédito.
	gastarb	foreign_worker	Detalle si el deudor es migrante.
	pers	people_liable	Total, de dependientes sobre el deudor.
	telef	telephone	La tenencia de un teléfono.
Categórico	moral	credit_history	Histórico del cumplimiento de créditos anteriores o simultáneos.
	wohn	housing	Tipo de vivienda.
	buerge	other_debtors	La existencia o no de un fiador.
	weitkred	other_installment_plans	Planes de pagos por otros proveedores diferentes a la entidad que otorga el crédito.
	famges	personal_status_sex	Sexo y estado matrimonial. Existen restricciones para separar la información ya que los hombres solteros y mujeres no solteras se codificaron igual. Así como las viudas.
	verw	purpose	La justificación del porqué del crédito.
	sparkont	savings	Los ahorros del deudor.
	laufkont	status	Estado de la cuenta del deudor.
Ordinal	beszeit	employment_duration	Los años laborados con el actual empleador.
	rate	installment_rate	Las cuotas en ratio según la entrada mensual del deudor.
	beruf	job	Calidad del trabajo del deudor.
	bishkred	number_credits	Total, de créditos.
	wohnzeit	present_residence	El tiempo vivido en la actual residencia (en años).
	verm	property	Propiedad de mayor valía.
Cuantitativo	alter	age	La edad del deudor.
	hoehe	amount	Monto del crédito. Con una transformación monótona.
	laufzeit	duration	Duración del crédito (en meses).

Construcción de Modelos




EXPERIMENTACIÓN

Se evalúan siete algoritmos (Regresión Logística, Random Forest, XGBoost, etc.) para encontrar el de mayor rendimiento.



PLAZO

El prototipado y la selección del modelo tomarán entre 2 y 4 semanas.



MLOPS EN PRÁCTICA

La arquitectura está diseñada para el reentrenamiento automatizado del modelo en producción, asegurando que su rendimiento no se degrade con el tiempo.

[Volver a la Agenda](#)

Realización de Predicciones

El sistema está diseñado para integrarse de manera fluida en el flujo de trabajo diario, sin generar interrupciones.

[Volver a la Agenda](#)

MODO DE EJECUCIÓN

Las predicciones se realizan en tiempo real, una por una.

FRECUENCIA

Se activa a demanda cada vez que un analista evalúa una nueva solicitud.

LATENCIA

La respuesta es casi inmediata, en menos de 2 segundos, para una experiencia de usuario óptima.

MATRIZ DE COSTO/BENEFICIO

Asignamos un valor monetario a cada predicción, penalizando fuertemente los Falsos Positivos (riesgo alto).

MÉTRICA CLAVE

Calculamos el Valor Monetario Esperado (EMV) sobre un set de validación histórico.

CRITERIOS DE DESPLIEGUE

El modelo solo se implementará si demuestra un EMV positivo y cumple con estrictas métricas de rendimiento y equidad.

Simulación del Impacto

Antes de entrar en producción, simulamos el impacto financiero del modelo para garantizar un retorno de inversión positivo.

[Volver a la Agenda](#)



Agencia G57

Midiendo el Éxito de Forma Continua



INDICADORES PARA EL USUARIO (REVISIÓN MENSUAL)

Tasa de Adopción y Satisfacción.



INDICADORES DE MODELO (REVISIÓN TRIMESTRAL)

Precisión y Volumen de Solicitudes.




INDICADORES DE NEGOCIO (REVISIÓN ANUAL)

Tasa de Incumplimiento y Retorno de la Inversión (ROI).

[Volver a la Agenda](#)



G57



Conclusiones sobre ML Engineer

El entorno de entrenamiento y la gestión del data drift garantizan un modelo estable, reproducible y justo.

Gracias a herramientas como DVC, MLflow y Evidently AI, aseguramos:


- Monitoreo continuo de datos y desempeño.
- Reentrenamientos automáticos ante desviaciones.
- Trazabilidad completa desde los datos hasta el despliegue.

Esto permite mantener un modelo confiable y adaptable, capaz de sostener decisiones de negocio precisas a lo largo del tiempo.

[Volver a la Agenda](#)



G57




Conclusiones sobre DevOps

- La configuración de infraestructura externa de acopio de datos es intrincada y muy volátil. En el caso de DVS la integración con GitHub ha sido un reto según las políticas de integración con la nube de Google y el set-up en el equipo de trabajo, **pero al final G57 consigue la prestación de un servicio integrado.**
- En cuanto a la prestancia de un medio de registro, versionado y observabilidad de los modelos entrenados; MLFlow ha sido configurado con éxito, sin embargo, las fuentes oficiales (tanto de MLFlow cómo de GCP) no otorgan un producto listo para usarse. **G57 tuvo que crear un contenedor especializado, basado en la prueba y el error.**

[Volver a la Agenda](#)



G57



Conclusiones Científico de Datos

El análisis del South German Credit Dataset permitió desarrollar un prototipo funcional de pipeline MLOps orientado a la predicción del riesgo crediticio de clientes. A lo largo del proceso, se implementaron buenas prácticas de Data Science aplicadas a un entorno de producción controlado, incluyendo la limpieza, transformación y codificación de variables, así como la comparación sistemática de distintos modelos de clasificación supervisada.


Desde una perspectiva analítica, los resultados muestran que la calidad de las predicciones depende de preparación de los datos y del manejo de clases desbalanceadas. Asimismo, el uso de pipelines permitió integrar de manera reproducible las etapas de preprocesamiento, muestreo y modelado, facilitando la evaluación comparativa y la detección de sobreajuste.

Como resultado, se obtuvo una visión clara del comportamiento de los modelos y su desempeño en métricas clave como AUC, Recall y F1-score, elementos esenciales para aplicaciones de riesgo financiero. Este primer avance constituye el inicio de una solución completa.

[Volver a la Agenda](#)



G57



Conclusiones sobre Data Engineer

- Para la etapa de prototipado trabajar en **notebooks** permitió entender la estructura del dataset, probar transformaciones y definir las variables clave del modelo. Sin embargo se hace presente la necesidad de avanzar desde la **exploración manual a la estandarización y automatización de tareas**, esto sienta las bases para **refactorizar procesos hacia scripts y pipelines reproducibles**.
- **DVC y GitHub** garantizan **trazabilidad, control de cambios y acceso compartido**. Esta práctica abre el camino a incorporar un **almacenamiento centralizado en la nube** (como GCS) y pipelines que gestionen **automáticamente nuevas versiones**.
- Para que nuestro modelo sea **escalable** es necesario **industrializar** el flujo: almacenar datos en zonas **estructuradas** (raw, staging, curated), **automatizar** el preprocesamiento y habilitar **pipelines** orquestados.

[Volver a la Agenda](#)



G57



Conclusiones Software Engineer

La responsabilidad del Ingeniero de Software se centrará en 3 áreas clave:

- **Crear la Herramienta:** Desarrolla la aplicación con la que interactúa el analista y la API en el servidor que recibe los datos. Es el encargado de construir la "cara visible" y funcional de todo el sistema.
- **Integrar el Modelo:** Conecta la aplicación con el modelo de ML para que pueda generar predicciones. Se asegura de que la herramienta utilice siempre la versión correcta y aprobada del modelo, cargándola desde un registro centralizado.
- **Garantizar la Calidad y el Rendimiento:** Transforma el prototipo en un producto robusto y profesional. Su foco es asegurar que la herramienta sea rápida (con respuestas menores a 2 segundos) , segura, escalable y fácil de usar para garantizar su adopción.

[Volver a la Agenda](#)

Enlace del vídeo del proyecto:



<https://youtu.be/DE6IKPMnQJM>

Enlace del Github del proyecto:



https://github.com/Oscar-Gj/MLOps_E57



G57

Gracias