

# Introducción

Como equipo consultor de G57, hemos delineado la implementación estratégica de un modelo de machine learning para mejorar el proceso de evaluación de riesgo crediticio de una entidad bancaria prestamista. Este documento detalla cada componente del ML Canvas, alineándose con sólidos principios de MLOps para asegurar una solución escalable, mantenible y de alto valor.

## Tarea de Predicción

El objetivo fundamental de este proyecto es una tarea de clasificación binaria , diseñada para determinar si un solicitante de crédito es un candidato apto o no para recibir un préstamo bancario. La predicción se realiza sobre la entidad Cliente-Crediticio, mientras que la Entidad-Bancaria-Prestamista es la responsable de tomar la decisión final.

Los resultados posibles son estrictamente dos: el cliente es considerado apto para el crédito o no apto. Esta evaluación se basa en el análisis de un conjunto de características del cliente, que cubren su situación social, económico-financiera y personal , y el resultado se observa en un proceso posterior a dicho análisis.

## Propuesta de Valor

El núcleo de nuestra propuesta es la creación de un sistema de inteligencia aumentada para la toma de decisiones crediticias. El objetivo principal es apoyar el proceso de evaluación de riesgo crediticio de la Entidad-Bancaria-Prestamista mediante un sistema de aprendizaje automático. La solución no busca reemplazar el juicio del analista, sino fortalecerlo con un análisis objetivo y basado en datos.

El sistema generará una predicción binaria ("apto" o "no apto") sobre la capacidad de un solicitante de crédito para cumplir con sus obligaciones de pago. Esta predicción se convertirá en una recomendación directa para el analista:

- Si el resultado es positivo ("apto"), el sistema lo comunicará a la entidad para que esta pueda iniciar procesos anexos, como la oferta de productos financieros específicos.
- Si el resultado es negativo ("no apto"), se recomendará detener el proceso para evitar una posible pérdida por incumplimiento.

El valor reside en mejorar la asignación de créditos, aumentar la eficiencia operativa y reducir el riesgo en la cartera de la entidad.

# Decisiones

Las predicciones del modelo se convierten directamente en recomendaciones prácticas que guían las decisiones de negocio. El sistema proporciona un resultado finito que indica si un cliente es un sujeto potencial calificado para un producto de crédito. Este resultado permite al analista tomar una acción inmediata:

- Un resultado positivo inicia las siguientes etapas del proceso comercial, como la selección y oferta de productos financieros adecuados para el cliente.
- Un resultado negativo detiene de forma inmediata cualquier proceso anexo, optimizando el tiempo del analista y evitando la asignación de recursos a un caso de alto riesgo.

El parámetro fundamental es el modelo de clasificación que utiliza las características del cliente como insumos para predecir la variable objetivo 'kredit'. La aplicación opera bajo la directriz de ser una herramienta de apoyo que no reemplaza el criterio profesional del analista. El sistema está diseñado para presentar un resultado binario, a veces acompañado de un nivel de confianza, que sirve como base para la decisión final del experto humano.

# Recolección de Datos

La estrategia de recolección de datos está diseñada para asegurar la frescura, consistencia y trazabilidad de la información, utilizando una arquitectura robusta que evoluciona desde la ingesta inicial hasta su preparación para el modelado analítico.

En la fase de prototipado, el conjunto inicial de datos se obtiene de manera directa desde un archivo CSV que contiene el South German Credit Dataset. Sin embargo, para un ambiente productivo, la recolección se automatiza. La conexión con las fuentes de datos internas se establece mediante consultas SQL ejecutadas sobre motores como Amazon RDS, Aurora o Redshift, utilizando herramientas como AWS Glue Connections, JDBC connectors o AWS Data Pipeline para automatizar la extracción.

La actualización de los datos se implementa a través de "jobs" de carga periódica que se ajustan a las necesidades del negocio y a los acuerdos de nivel de servicio (SLA). Estas cargas pueden ejecutarse con distintas frecuencias:

- **En línea** (streaming), para disponibilidad inmediata.
- **Al cierre del día** (batch diario), para consolidación nocturna.
- **Semanal o mensual**, para optimizar costos y trabajar con datos más agregados.

Para gestionar el ciclo de vida de la información, se propone una arquitectura de tres etapas:

- **Etapas** 1: Raw – Ingesta: El objetivo es capturar y almacenar los datos originales sin

transformaciones en una zona de ingesta como Amazon S3. Esto mantiene una copia inmutable para fines de auditoría, registrando metadatos a través de AWS Glue Data Catalog y versionando cada carga.

- **Etapas 2:** Staging – Procesamiento: En esta fase, los datos se validan, limpian y transforman para su uso analítico. Las acciones clave incluyen la revisión y tratamiento de valores faltantes o inconsistentes, la codificación de variables categóricas, la normalización de escalas numéricas y la creación de variables derivadas, como el ratio de deuda.
- **Etapas 3:** Curated – Data Procesada: Finalmente, los datos completos y validados se consolidan, listos para el análisis o entrenamiento de modelos. En esta etapa se integra la etiqueta definitiva (`credit_risk`) y se exportan los datos a formatos eficientes como Parquet, para luego cargarlos en Amazon Redshift o consultarlos con Athena. Esta capa es el insumo principal para el reentrenamiento de los modelos de Machine Learning en plataformas como AWS SageMaker.

## Fuentes de Datos

Para este proyecto, los datos sobre las entidades y sus resultados se obtienen de una combinación de fuentes externas e internas, garantizando una cobertura completa tanto para la fase de prototipado como para la operación en un entorno productivo.

- **Fuente Interna (Fase Inicial):** Para la etapa inicial, la principal fuente de información es el South German Credit Dataset, disponible en el repositorio de la University of California, Irvine (UCI). Este conjunto de datos es fundamental, ya que provee información estructurada y en bruto sobre solicitantes de crédito, incluyendo sus atributos financieros, demográficos y socioeconómicos, junto con la variable objetivo **`credit_risk`** que indica su comportamiento de pago.
- **Fuentes Externas (Fase de Producción):** En un entorno productivo, la información provendrá directamente de las bases de datos propias de la institución financiera. Esto incluye el acceso a tablas de clientes o solicitantes con datos personales, sociales y económicos; tablas de transacciones crediticias que detallan los préstamos otorgados; y tablas de resultados de crédito, que reflejan el cumplimiento o incumplimiento de los pagos, representado por la variable **`kredit`**.
- **Fuentes Externas (Fase de Producción):** Para enriquecer el perfil de los clientes, los datos internos se podrían complementar con información proveniente de fuentes externas, la cual se gestionaría a través de APIs.

# Características

Cada solicitante de crédito se representa mediante un vector de características compuesto por datos numéricos y categóricos extraídos de las fuentes de datos sin procesar. La siguiente tabla presenta un diccionario de datos detallado. Los parámetros se han organizado en cuatro familias según su tipo (**Binario**, **Categórico**, **Ordinal** y **Cuantitativo**), y para cada uno se especifica su nombre canónico original, su traducción para el análisis y una descripción de su significado.

Familia del Parámetro	Canónico original	Parámetro traducido	Detalle
<b>Binario</b>	kredit	credit_risk	Cumplimiento o no cumplimiento del crédito.
	gastarb	foreign_worker	Detalle si el deudor es migrante.
	pers	people_liable	Total, de dependientes sobre el deudor.
	telef	telephone	La tenencia de un teléfono.
<b>Categórico</b>	moral	credit_history	Histórico del cumplimiento de créditos anteriores o simultáneos.
	wohn	housing	Tipo de vivienda.
	buerge	other_debtors	La existencia o no de un fiador.
	weitkred	other_installment_plans	Planes de pagos por otros proveedores diferentes a la entidad que otorga el crédito.
	famges	personal_status_sex	Sexo y estado matrimonial. Existen restricciones para separar la información ya que los hombres solteros y mujeres no solteras se codificaron igual. Así como las viudas.
	verw	purpose	La justificación del porqué del crédito.
	sparkont	savings	Los ahorros del deudor.
	laufkont	status	Estado de la cuenta del deudor.
<b>Ordinal</b>	beszeit	employment_duration	Los años laborados con el actual empleador.
	rate	installment_rate	Las cuotas en ratio según la entrada mensual del deudor.
	beruf	job	Calidad del trabajo del deudor.
	bishkred	number_credits	Total, de créditos.
	wohnzeit	present_residence	El tiempo vivido en la actual residencia (en años).
	verm	property	Propiedad de mayor valía.
<b>Cuantitativo</b>	alter	age	La edad del deudor.
	hoehe	amount	Monto del crédito. Con una transformación monótona.
	laufzeit	duration	Duración del crédito (en meses).

Para que estas características sin procesar sean efectivas, se someterán al siguiente preprocesamiento riguroso:

- **Limpieza de datos**
  - Eliminación o imputación de valores nulos.
  - Detección y tratamiento de valores atípicos.
- **Transformaciones de variables**
  - Normalización o estandarización de las variables numéricas.

- Codificación de variables categóricas mediante one-hot encoding o codificación ordinal.
- **Balanceo de clases** (si es necesario)
  - Dado que la proporción de clientes aprobados vs. no aprobados puede estar desbalanceada, se aplicarán técnicas como SMOTE o undersampling para equilibrar las clases y evitar sesgos en el modelo.
- **División en conjuntos de datos**
  - Los datos se dividen en train, validation y test para asegurar que el modelo generalice correctamente y que la evaluación sea justa.
  - En el caso de la base de datos de prototipo solo se divide en train y validación por que la base de datos es muy pequeña.

## Construcción de Modelos

Nuestra estrategia de modelado se basa en la exploración y comparación rigurosa para identificar el algoritmo de mejor rendimiento. Para ello, evaluaremos los siguientes modelos logrando una diversidad que nos permite contrastar rendimiento, interpretabilidad y coste computacional:

- Regresión Logística
- k-Nearest Neighbors (k-NN)
- Árbol de Decisión (Decision Tree)
- Random Forest
- Extreme Gradient Boosting (XGBoost)
- Multi-Layer Perceptron (MLP)
- Support Vector Classifier (SVC)

El ciclo de desarrollo comenzará con una fase de prototipado rápido utilizando el dataset de estudio en entornos accesibles como Google Colab. Una vez validado el enfoque, estaremos preparados para el escalamiento a producción. Esto podría requerir el uso de infraestructura más potente, incluyendo GPUs dedicadas y mayor memoria RAM en plataformas en la nube, para manejar volúmenes de datos mucho mayores y reducir los tiempos de entrenamiento. El proceso completo, desde la exploración de datos hasta la selección del modelo final, se estima en un marco temporal de 2 a 4 semanas.

## Realizando predicciones

Las predicciones se realizan en tiempo real y una por una. No se procesa una gran lista de clientes al mismo tiempo, sino que el sistema responde al instante cada vez que un analista está atendiendo una nueva solicitud de crédito.

La frecuencia es a demanda, es decir, el sistema se activa únicamente cuando un analista necesita evaluar a un nuevo cliente. La herramienta está diseñada para dar una respuesta casi inmediata, en cuestión de segundos. El objetivo es que el analista obtenga la recomendación mientras está con el cliente, sin generar esperas que interrumpan su trabajo.

Para que el sistema funcione, se requieren algunos recursos tecnológicos específicos. En primer lugar, se utiliza la computadora del analista (cliente), desde donde se ingresan los datos del cliente de la manera habitual. Así como un servidor central, que puede estar alojado dentro de la infraestructura del banco o en la nube, y es el lugar donde se ejecuta el modelo de aprendizaje automático. Cuando el analista envía la información del cliente, estos datos se transmiten a través de la red hasta el servidor, que procesa la información y devuelve el resultado directamente a la pantalla del analista, indicando si el cliente es recomendado o no recomendado para recibir un crédito.

## Simulación de Impacto

Un modelo solo es valioso si genera un impacto positivo en el negocio. Por ello, antes del despliegue, realizaremos una simulación exhaustiva para cuantificar su Valor Monetario Esperado (EMV). Esta simulación se basará en una matriz de costo/beneficio que asigna un valor a cada posible resultado, reconociendo que el costo de un Falso Positivo es significativamente mayor que la pérdida de oportunidad de un Falso Negativo.

Tipo de decisión	Predicción del modelo	Realidad	Consecuencia	Valor estimado
<b>Verdadero Positivo (VP)</b>	Cliente "apto"	Cliente paga correctamente	Beneficio: se otorga crédito y se obtiene ganancia por intereses.	+1.0 unidad de beneficio neto
<b>Falso Positivo (FP)</b>	Cliente "apto"	Cliente no paga	Costo: pérdida del capital prestado, gastos administrativos, deterioro de cartera.	-3.0 unidades (riesgo alto)
<b>Verdadero Negativo (VN)</b>	Cliente "no apto"	Cliente efectivamente hubiera incumplido	Beneficio: se evita una pérdida potencial.	+0.5 unidades (beneficio de prevención)
<b>Falso Negativo (FN)</b>	Cliente "no apto"	Cliente sí hubiera pagado bien	Costo: pérdida de oportunidad de ingresos por intereses y cliente insatisfecho.	-1.0 unidad (costo reputacional y de oportunidad)

El modelo solo se implementará si cumple con los siguientes requisitos técnicos y de negocio:

### Rendimiento del Modelo:

- **Precisión mínima:**  $\geq 80\%$  en validación.
- **Recall** (para la clase "riesgo alto"):  $\geq 70\%$  para limitar la aprobación de clientes morosos.

- **Ganancia Neta (EMV):** Debe ser positiva en el escenario de validación.
- **Tiempo de respuesta:** Inferior a 2 segundos por predicción.

#### Restricciones de Equidad:

- El modelo debe evitar sesgos hacia grupos protegidos (género, estado civil).
- Se utiliza la métrica Equal Opportunity Difference para comparar la tasa de verdaderos positivos entre subgrupos. Si la diferencia excede el  $\pm 0.1$ , el modelo debe ser reequilibrado.

## Monitoreo

El despliegue no es el final del proceso, sino el comienzo del monitoreo continuo. Para ello, hemos definido KPIs clave para una visión 360° del rendimiento de la solución.

#### Indicadores para los Analistas o Usuarios Finales

- **Tasa de Adopción:** ¿Cuántos analistas realmente usan la herramienta todos los días? Si no la usan, algo anda mal.
- **Tiempo por Solicitud:** Medimos cuánto tiempo tardan ahora en evaluar un crédito en comparación con antes. El objetivo es que sean más rápidos.
- **Satisfacción del Usuario:** A través de encuestas cortas acerca de qué tan contentos están con la herramienta y si les parece útil.

#### Indicadores para el Banco

- **Tasa de Incumplimiento:** Comparamos el porcentaje de préstamos malos entre los créditos aprobados usando la herramienta contra los que se aprobaron antes. La meta es que este número baje.
- **Precisión del Modelo:** De todos los créditos que el sistema marcó como "Recomendados", ¿qué porcentaje realmente pagó bien? Esto nos dice qué tan acertado es el modelo.
- **Volumen de Solicitudes Procesadas:** ¿El banco es capaz de evaluar más solicitudes de crédito en el mismo periodo de tiempo?
- **Retorno de la Inversión (ROI):** Comparamos el costo de desarrollar y mantener la herramienta contra el dinero que el banco se ha ahorrado al evitar malos préstamos. Al final del día, la solución debe ser rentable.

Estos KPIs se revisarán con diferentes frecuencias:

- **Revisión Semanal o Mensual:** Los indicadores de los usuarios (adopción, tiempo por solicitud, tasa de corrección manual). Estos nos permiten detectar rápidamente si los analistas tienen problemas con la herramienta.

- **Revisión Trimestral:** La precisión del modelo y el volumen de solicitudes. Aquí ya tenemos suficientes datos para ver si la herramienta funciona como se esperaba a nivel técnico y operativo.
- **Revisión Semestral o Anual:** La tasa de incumplimiento y el ROI. Estos indicadores son más lentos, ya que se necesita tiempo para saber si un cliente realmente va a dejar de pagar su crédito. Son la prueba final del éxito del proyecto.

## Referencias

- Sandí, R. (2024) *Problema de asignación de créditos: South German Dataset. Inteligencia Artificial y Aprendizaje Automático Actividad Semanas 5 y 6*. MNA. Tecnológico de Monterrey. Recuperado en octubre 5, 2025 de [https://github.com/Tecnologico-de-Monterrey-MNA/tareas-iajaa-em-2024-A01794620/blob/a8650ba31572031e5000e7a04cc2c50d33a64044/wk05\\_06/MNA\\_IAYAA\\_semana\\_5\\_y\\_6\\_Actividad.ipynb](https://github.com/Tecnologico-de-Monterrey-MNA/tareas-iajaa-em-2024-A01794620/blob/a8650ba31572031e5000e7a04cc2c50d33a64044/wk05_06/MNA_IAYAA_semana_5_y_6_Actividad.ipynb)
- South German Credit [Dataset]. (2020). UCI Machine Learning Repository. <https://doi.org/10.24432/C5QG8>



# ML Canvas

<b>PREDICTION TASK</b> <b>Tarea:</b> Clasificación binaria de aptitud crediticia. <b>Entidad:</b> Cliente-Crediticio (solicitante de crédito). <b>Variable objetivo:</b> credit_risk - Cumplimiento o incumplimiento de pago. <b>Resultados:</b> Apto / No apto para crédito. <b>Observación:</b> Posterior al análisis de características sociales, económicas y personales.	<b>DECISIONS</b> <b>Resultado positivo:</b> Iniciar procesos comerciales (oferta de productos financieros). <b>Resultado negativo:</b> Detener proceso inmediatamente para evitar pérdidas. Rol del sistema: Herramienta de apoyo que fortalece (no reemplaza) el criterio del analista. <b>Salida:</b> Predicción binaria con nivel de confianza opcional.	<b>VALUE PROPOSITION</b>  <b>Usuario final:</b> Analistas crediticios de la Entidad-Bancaria-Prestamista.  <b>Objetivo principal:</b> Sistema de inteligencia aumentada para mejorar el proceso de evaluación de riesgo crediticio.  <b>Beneficios clave:</b> <ul style="list-style-type: none"><li>Mejora en la asignación de créditos mediante análisis objetivo basado en datos</li><li>Aumento de la eficiencia operativa del proceso de evaluación</li><li>Reducción del riesgo en la cartera crediticia de la entidad</li><li>Optimización del tiempo del analista evitando asignación de recursos a casos de alto riesgo</li></ul> <b>Flujo de trabajo:</b> El sistema genera predicciones que se comunican a la entidad para facilitar la toma de decisiones sobre aprobación crediticia y oferta de productos financieros.	<b>DATA COLLECTION</b> <b>Prototipo:</b> Ingesta directa desde CSV (South German Credit Dataset). <b>Producción:</b> Automatización vía SQL queries sobre AWS RDS/Aurora/Redshift con AWS Glue/JDBC. <b>Frecuencias:</b> Streaming, batch diario, semanal o mensual según SLA.  <b>Arquitectura de 3 capas:</b> <ul style="list-style-type: none"><li><b>Raw:</b> Almacenamiento inmutable en S3 con versionado</li><li><b>Staging:</b> Limpieza, validación, transformaciones y codificaciones</li><li><b>Curated:</b> Datos listos en Parquet para análisis/reentrenamiento en SageMaker</li></ul>	<b>DATA SOURCES</b> <b>Prototipo:</b> South German Credit Data (UCI). <b>Producción - Internas:</b>  Tablas de clientes con datos personales/sociales/económicos Transacciones crediticias Resultados de pago (variable kredit)  <b>Producción - Externas:</b> Enriquecimiento vía APIs para complementar perfiles.
<b>IMPACT SIMULATION</b> <b>Matriz Costo/Beneficio:</b> <b>VP</b> (apto/paga): +1.0 <b>FP</b> (apto/no paga): -3.0 <b>VN</b> (no apto/hubiera incumplido): +0.5 <b>FN</b> (no apto/hubiera pagado): -1.0  <b>Requisitos de implementación:</b> Precisión ≥ 80% Recall ≥ 70% (clase riesgo alto) EMV positivo Tiempo respuesta < 2 seg Equal Opportunity Difference ≤ ±0.1 (equidad)	<b>MAKING PREDICTIONS</b> <b>Modalidad:</b> Predicciones individuales en tiempo real a demanda. <b>Tiempo de respuesta:</b> < 2 segundos.  <b>Infraestructura:</b> <b>Cliente:</b> PC del analista <b>Servidor:</b> Cloud/on-premise con modelo ML <b>Flujo:</b> Ingreso datos → transmisión → procesamiento → resultado en pantalla	<b>BUILDING MODELS</b> <b>Modelos evaluados (7):</b> Regresión Logística, k-NN, Árbol de Decisión, Random Forest, XGBoost, MLP, SVC.  <b>Criterios:</b> Rendimiento, interpretabilidad, costo computacional.  <b>Desarrollo:</b> <ul style="list-style-type: none"><li>Prototipado en Google Colab</li><li>Escalamiento a producción en AWS SageMaker con GPU</li></ul> <b>Timeline:</b> 2-4 semanas.	<b>FEATURES</b> <b>Total:</b> 20 características en 4 familias. <b>Binarias (4):</b> credit_risk, foreign_worker, people_liable, telephone <b>Categorías (7):</b> credit_history, housing, other_debtors, installment_plans, personal_status_sex, purpose, savings, status <b>Ordinales (6):</b> employment_duration, installment_rate, job, number_credits, present_residence, property <b>Cuantitativas (3):</b> age, amount, duration Preprocesamiento:  Limpieza: imputación de nulos, tratamiento de outliers Transformaciones: normalización, codificación one-hot/ordinal Balanceo: SMOTE/undersampling si necesario División: train/validation/test	
<b>MONITORING</b> <b>KPIs para Analistas (Usuarios Finales):</b> <ul style="list-style-type: none"><li>Tasa de Adopción: % de analistas usando la herramienta diariamente</li><li>Tiempo por Solicitud: Reducción vs. proceso anterior</li><li>Satisfacción del Usuario: Encuestas sobre utilidad y experiencia</li></ul> <b>KPIs para el Banco (Negocio):</b> <ul style="list-style-type: none"><li>Tasa de Incumplimiento: % préstamos malos con herramienta vs. sin herramienta</li><li>Precisión del Modelo: % de créditos "Recomendados" que pagaron correctamente</li><li>Volumen de Solicitudes Procesadas: Capacidad de evaluación en mismo periodo</li><li>Retorno de Inversión (ROI): Costo desarrollo/mantenimiento vs. ahorros por evitar malos préstamos</li></ul> <b>Frecuencia:</b> <ul style="list-style-type: none"><li>Semanal/Mensual: Adopción, tiempo por solicitud, correcciones manuales (detección rápida de problemas operativos)</li><li>Trimestral: Precisión del modelo, volumen de solicitudes (validación técnica y operativa)</li><li>Semestral/Anual: Tasa de incumplimiento, ROI (prueba final de éxito del proyecto)</li></ul>				